

RELATÓRIO DO LABORATÓRIO ESTATÍSTICO INTERATIVO

1. Introdução

Este trabalho apresenta o desenvolvimento de um Laboratório Estatístico Interativo em Python. A aplicação foi criada para permitir a exploração de um conjunto de dados reais por meio de estatística descritiva, simulações, distribuições de probabilidade, correlação e regressão linear.

A aplicação utiliza Streamlit para apresentar os resultados de forma interativa. As principais funções estatísticas foram implementadas no próprio projeto e posteriormente comparadas com bibliotecas estatísticas para validação.

2. Dataset escolhido

O dataset utilizado foi o Australian Fatal Road Accident 1989--2021, disponibilizado publicamente no Kaggle.

Fonte:

<https://www.kaggle.com/datasets/deepcontractor/australian-fatal-car-accident-data-19892021>

O arquivo utilizado no projeto é Crash_Data.csv.

O conjunto possui 52.843 registros de acidentes rodoviários fatais ocorridos na Austrália entre 1989 e 2021.

As variáveis numéricas utilizadas foram:

Month Year Speed Limit Age

As variáveis categóricas utilizadas foram:

State Gender Crash Type Road User

Crash ID foi tratado como identificador do registro e não como variável numérica para as análises.

A escolha do dataset ocorreu porque ele atende aos requisitos mínimos da atividade e permite trabalhar com diferentes tipos de variáveis e análises estatísticas.

Laboratório Estatístico Interativo

Explore os dados de acidentes rodoviários da Austrália por meio de diferentes ferramentas estatísticas.

Visão geral dos dados

O conjunto de dados reúne registros de acidentes rodoviários fatais ocorridos na Austrália entre 1989 e 2021.

Registros	Período inicial	Período final	Variáveis analisadas
52.843	1989	2021	8

Variáveis numéricas

Month, Year, Speed Limit, Age

Variáveis categóricas

State, Gender, Crash Type, Road User

A variável Crash ID é utilizada como identificador de cada registro e não é considerada uma variável numérica para as análises estatísticas.

3. Implementação do núcleo estatístico

O arquivo minhastats.py contém as principais funções estatísticas desenvolvidas no projeto.

Foram implementadas funções para:

Média Mediana Moda Amplitude Variância amostral e populacional Desvio padrão amostral e populacional Percentis Quartis Coeficiente de variação Covariância Correlação de Pearson Regressão linear Coeficiente de determinação R^2

Média

A média foi calculada pela soma dos valores dividida pela quantidade de observações:

$$\mu = (1/n) \sum x_i$$

Mediana e moda

A mediana é obtida após ordenar os valores. Para uma quantidade ímpar de observações, utiliza-se o valor central. Para uma quantidade par, utiliza-se a média dos dois valores centrais.

A moda é obtida pela contagem das ocorrências de cada valor, identificando aquele ou aqueles que apresentam maior frequência.

Amplitude

A amplitude foi calculada pela diferença entre o maior e o menor valor:

$$A = x_{\max} - x_{\min}$$

Variância e desvio padrão

Foram implementadas as versões amostral e populacional.

Variância amostral:

$$s^2 = \sum (x_i - \bar{x})^2 / (n - 1)$$

Variância populacional:

$$\sigma^2 = \sum (x_i - \mu)^2 / n$$

O desvio padrão é obtido pela raiz quadrada da variância.

Percentis e quartis

Os percentis são calculados a partir dos valores ordenados, utilizando interpolação quando necessário.

Os quartis utilizados são:

$$Q1 = P25 \quad Q2 = P50 \quad Q3 = P75$$

Coeficiente de variação

O coeficiente de variação foi calculado por:

$$CV = (s / \bar{x}) \times 100$$

Covariância e correlação de Pearson

A covariância foi implementada considerando os desvios de cada observação em relação às médias das duas variáveis.

A correlação de Pearson foi implementada pela fórmula:

$$r = \sum [(x_i - \bar{x})(y_i - \bar{y})] / \sqrt{[\sum (x_i - \bar{x})^2 \sum (y_i - \bar{y})^2]}$$

Regressão linear e R²

A inclinação da reta foi calculada por:

$$m = \sum [(x_i - \bar{x})(y_i - \bar{y})] / \sum (x_i - \bar{x})^2$$

O intercepto foi calculado por:

$$b = \bar{y} - m\bar{x}$$

Assim, a reta de regressão é representada por:

$$\hat{y} = mx + b$$

O coeficiente de determinação foi calculado por:

$$R^2 = 1 - \sum (y_i - \hat{y}_i)^2 / \sum (y_i - \bar{y})^2$$

4. Validação dos cálculos

As funções desenvolvidas foram testadas e comparadas com resultados obtidos por bibliotecas como NumPy e SciPy.

Foi utilizada uma tolerância de 10^{-9} para considerar pequenas diferenças de representação numérica.

Também foram criados testes para as funções de simulação e distribuição de probabilidade.

Ao final da execução dos testes automatizados, foram obtidos:

30 testes aprovados.

```
(.venv) C:\Users\alexc\OneDrive\Área de Trabalho\LaboratorioEstatistico>pytest
===== test session starts =====
platform win32 -- Python 3.14.7, pytest-9.1.1, pluggy-1.6.0
rootdir: C:\Users\alexc\OneDrive\Área de Trabalho\LaboratorioEstatistico
plugins: anyio-4.15.1
collected 30 items

tests\test_distribuicoes.py .... [ 13%]
tests\test_minhastats.py ..... [ 86%]
tests\test_simulacoes.py .... [100%]

===== 30 passed in 10.37s =====
```


5. Módulo 2 -- Estatística descritiva

O módulo permite selecionar uma variável numérica e apresenta medidas de tendência central e dispersão.

Entre os resultados apresentados estão média, mediana, moda, amplitude, variância, desvio padrão, coeficiente de variação, quartis e IQR.

Também são apresentados tabelas de frequência, identificação de outliers, histogramas e boxplots.

Para as variáveis Age e Speed Limit, a aplicação também permite visualizar uma curva de distribuição normal sobre o histograma e apresenta uma interpretação da assimetria.




6. Módulo 3 -- Simulações

O módulo apresenta simulações relacionadas à Lei dos Grandes Números e ao Teorema Central do Limite.

Na simulação da Lei dos Grandes Números, são realizados lançamentos de uma moeda e acompanhada a proporção de caras ao longo das repetições. A proporção tende a se aproximar de 0,5 conforme aumenta a quantidade de lançamentos.

Na simulação do Teorema Central do Limite, são geradas várias amostras a partir dos dados e calculadas suas médias. O histograma das médias amostrais permite observar a tendência de formação de uma distribuição aproximadamente normal.



7. Módulo 4 -- Distribuições

Foram implementadas as distribuições Normal e Poisson.

Distribuição Normal

A distribuição normal é utilizada na aplicação para comparar a distribuição teórica com dados observados. Seus parâmetros são obtidos a partir dos dados analisados.

Distribuição de Poisson

Para a análise de Poisson, os registros foram agrupados por ano e mês, utilizando Crash ID para contar acidentes distintos.

O período de 1989 a 2021 possui 396 meses.

A média de acidentes por mês foi:

$$\lambda = 120,12$$

A variância observada foi aproximadamente:

978,96

A razão entre a variância e a média foi aproximadamente:

8,15

Na distribuição de Poisson, a média e a variância teóricas são iguais. Como a variância observada é consideravelmente maior que a média, a aplicação identifica sobredispersão nos acidentes mensais.

Esse comportamento também explica a diferença entre a distribuição observada e a curva teórica de Poisson apresentada no gráfico.

Distribuições de probabilidade


Nesta seção, os dados reais são comparados com distribuições teóricas de probabilidade.

Distribuição de Poisson

Quantidade de meses	Média mensal	Variância mensal
396	120.12	978.96

Razão entre variância e média: 8.15

A variância (978.96) é aproximadamente 8.15 vezes maior que a média (120.12). Isso indica sobredispersão, ou seja, os acidentes mensais apresentam uma variabilidade maior do que a esperada por uma distribuição de Poisson.



A comparação entre os dados reais e a distribuição de Poisson permite avaliar visualmente se o modelo teórico representa adequadamente a quantidade de acidentes por mês.

8. Módulo 5 -- Correlação e regressão

O módulo permite selecionar duas variáveis numéricas para analisar sua relação.

São apresentados o coeficiente de correlação de Pearson, a equação da regressão linear, o R^2 , uma previsão para um valor informado pelo usuário e um gráfico de dispersão com a reta de regressão.

A aplicação também apresenta uma interpretação da direção e intensidade da correlação, da inclinação da reta, do intercepto e do percentual de variação explicado pelo modelo.

A análise representa uma associação linear entre as variáveis. Correlação ou regressão, por si só, não demonstram causalidade.

Correlação e regressão

Escolha duas variáveis numéricas para analisar a relação linear entre elas.

Variável X:
Age

Variável Y:
Speed Limit

Correlação de Pearson
-0.067

Inclinação
-0.0634

R^2
0.004

Intercepto: 85.5927

Equação da reta: $y = -0.0634x + 85.5927$

Previsão

Digite um valor de Age:

39

Valor previsto de Speed Limit

83

Interpretação

A correlação indica uma relação linear negativa muito fraca entre as variáveis.

Para cada aumento de 1 unidade em Age, o modelo prevê uma redução média de 0.0634 unidades em Speed Limit.

Quando Age é igual a 0, o modelo prevê 85.5927 para Speed Limit. Dependendo das variáveis escolhidas, esse valor pode não ter uma interpretação prática.

O modelo explica aproximadamente 0.45% da variação da variável Y.

A correlação e a regressão mostram apenas uma associação linear entre as variáveis. Isso não significa que uma variável cause a outra.

9. Módulo 6 -- Descobertas

Registros por gênero

No conjunto analisado foram encontrados:

Masculino: 37.813 registros Feminino: 15.002 registros Não especificado: 1 registro

Os dados apresentam uma quantidade diferente de registros entre os grupos de gênero.


1. Registros fatais envolvendo homens e mulheres

Homens	Mulheres	Razão
37.813	15.002	2.52

Foram registrados 37.813 casos envolvendo homens e 15.002 envolvendo mulheres.

Isso representa aproximadamente 2,52 registros envolvendo homens para cada registro envolvendo mulheres.

Registros fatais por gênero



Distribuição dos registros por estado

A quantidade de registros varia entre os estados australianos.

Alguns dos valores observados são:

NSW: 16.293 Vic: 11.562 Qld: 10.495 WA: 6.276 SA: 4.547

Essa comparação descreve a quantidade de registros no dataset. Ela não representa diretamente o risco de acidentes em cada estado, pois não considera população, frota de veículos ou exposição ao trânsito.

2. A quantidade de registros varia entre os estados

Maior quantidade

NSW

Menor quantidade

ACT


Diferença

34.09x

O estado com mais registros foi NSW, com 16.293 registros.

O estado com menos registros foi ACT, com 478 registros.

Isso representa uma diferença de aproximadamente 34,09 vezes entre os dois estados.



Distribuição por faixa etária


A aplicação também apresenta a quantidade de registros por grupo de idade, permitindo identificar as faixas etárias mais frequentes no conjunto de dados.

3. A faixa etária mais comum nos registros fatais

Faixa etária mais frequente

17-25

A faixa etária com mais registros foi 17-25, com 13.771 registros.



10. Conclusão

O Laboratório Estatístico Interativo reúne diferentes técnicas estatísticas em uma única aplicação, utilizando dados reais de acidentes rodoviários fatais na Austrália.

A implementação própria das principais funções estatísticas foi validada por meio de testes automatizados e comparação com bibliotecas estatísticas.

A análise também permitiu identificar diferenças na distribuição dos registros por gênero e estado, além da sobredispersão observada na quantidade mensal de acidentes, demonstrando a utilização das ferramentas estatísticas em um conjunto de dados real.